

BÀI TẬP xử lý chuỗi 1.2

Họ và tên: Nguyễn Quang Linh MSSV: 038205003016

```
In [2]: import pandas as pd
```

import dataSet

```
In [3]: file_path = '../data/Elearning01/smsspamcollection/SMSSpamCollection'
df = pd.read_csv(
    file_path,
    sep='\t',
    header=None,
    names=['Label', 'Message']
)
```

1. Đếm xem có bao nhiêu dòng và bao nhiêu dòng xuất hiện spam và bao nhiêu dòng xuất hiện ham trong file trên
2. Đếm xem có bao nhiêu từ (các từ ngăn cách bởi khoảng trắng, và không phải chữ số)
3. Đếm xem có bao nhiêu từ 'you' (không phân biệt hoa thường)
4. Đếm xem có bao nhiêu từ khác nhau (không phân biệt hoa thường)
5. Liệt kê 10 từ khóa xuất hiện nhiều nhất trong file dữ liệu (không phân biệt hoa thường)

```
In [4]: df.head()
```

```
Out[4]:
```

	Label	Message
0	ham	Go until jurong point, crazy.. Available only ...
1	ham	Ok lar... Joking wif u oni...
2	spam	Free entry in 2 a wkly comp to win FA Cup fina...
3	ham	U dun say so early hor... U c already then say...
4	ham	Nah I don't think he goes to usf, he lives aro...

1. Đếm xem có bao nhiêu dòng và bao nhiêu dòng xuất hiện spam và bao nhiêu dòng xuất hiện ham trong file trên

```
In [5]: df['Label'].value_counts()
```

```
Out[5]: Label
ham      4825
spam     747
Name: count, dtype: int64
```

2. Đếm xem có bao nhiêu từ (các từ ngăn cách bởi khoảng trắng, và không phải chữ số)

```
In [6]: df['word_count'] = df['Message'].apply(lambda x: len([w for w in x.split() if not w.isdigit()]))
df.head()
```

```
Out[6]:
```

	Label	Message	word_count
0	ham	Go until jurong point, crazy.. Available only ...	20
1	ham	Ok lar... Joking wif u oni...	6
2	spam	Free entry in 2 a wkly comp to win FA Cup fina...	26
3	ham	U dun say so early hor... U c already then say...	11
4	ham	Nah I don't think he goes to usf, he lives aro...	13

3. Đếm xem có bao nhiêu từ 'you' (không phân biệt hoa thường)

```
In [28]: you_count = df['Message'].apply(lambda x: x.lower().split().count('you'))
print(f'Count word you: {you_count.sum()}')
```

Count word you: 1921

4. Đếm xem có bao nhiêu từ khác nhau (không phân biệt hoa thường)

```
In [27]: all_words = df['Message'].str.lower().str.split().explode()

unique_words = all_words.unique()
print(f'The number of unique words: {len(unique_words)}')
```

The number of unique words: 13579

5. Liệt kê 10 từ khóa xuất hiện nhiều nhất trong file dữ liệu (không phân biệt hoa thường)

```
In [ ]: all_words = df['Message'].str.lower().str.split().explode()  
top10_words = all_words.value_counts().head(10)  
top10_words.plot.bar()  
print(top10_words)
```

```
Message  
to      2237  
i       2217  
you     1921  
a       1433  
the     1329  
Name: count, dtype: int64
```

